Báo cáo chạy thử UTMOSv2 trên tiếng Việt

Nov 7, 2026 · @Knight

Tóm tắt

UTMOSv2 không dự đoán được cảm nhận của người nghe Việt: trên 20 clip tiếng Việt, tương quan Spearman giữa điểm của model và điểm trung bình của 4 người nghe là −0.01.

- **Sai rõ nhất ở giọng tổng hợp (TTS).** Người nghe chấm giọng người thật 3.63 và TTS 1.68; cả 4 người đều xếp người thật cao hơn TTS. UTMOSv2 xếp ngược lại: TTS 2.68, người thật 2.49.
- **Model vẫn nhận ra nhiễu.** Trên các clip giọng người thật có hoặc không có nhiễu, điểm model tương quan vừa phải với người nghe (Spearman 0.55). Mức giảm điểm theo nhiễu ở tiếng Việt và tiếng Anh gần như nhau.
- **Kết quả khớp với nhận định của thầy, nhưng còn là chạy thử.** Mẫu nhỏ (20 clip, 4 người nghe là thành viên nhóm), và chưa có bài nghe tiếng Anh để đối chứng.

Thiết lập

Nhóm chạy nguyên bản model pretrained của UTMOSv2, không train hay sửa, rồi so điểm của model với điểm người nghe Việt.

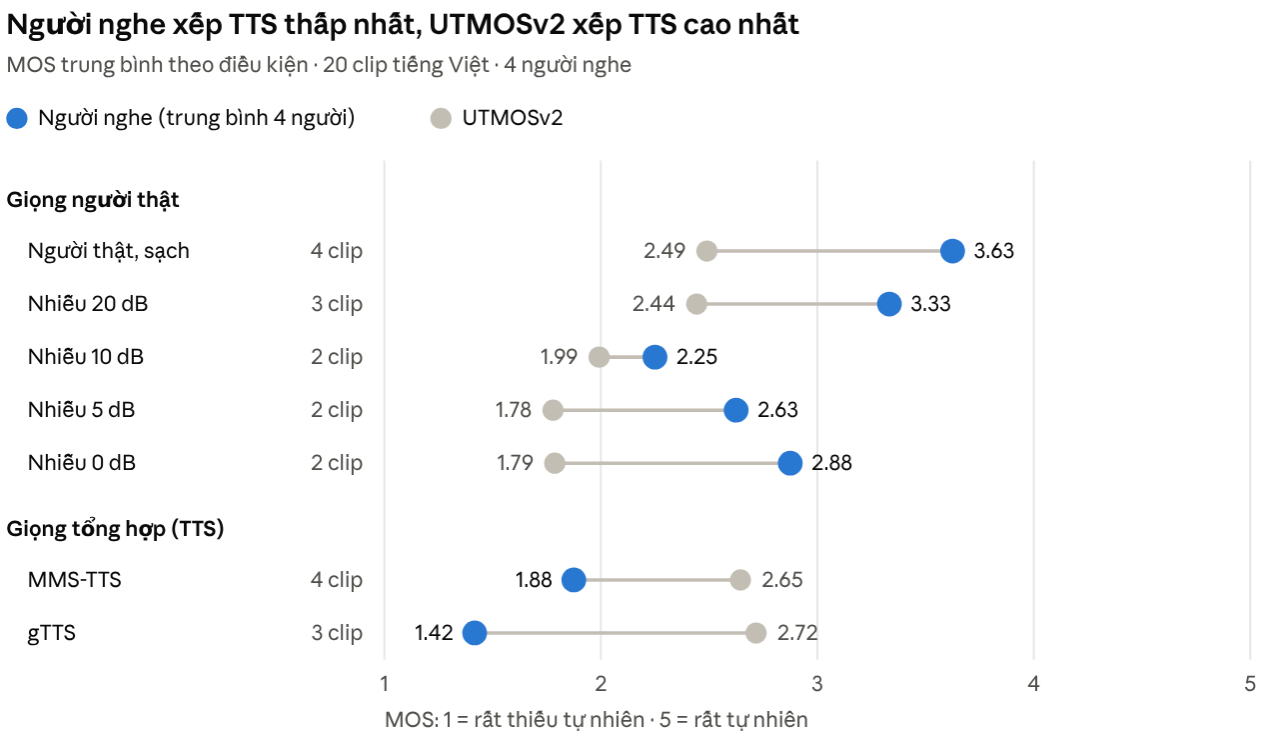
Hạng mục	Chi tiết
Mã nguồn	sarulab-speech/UTMOSv2, commit `cc2700d`
Cấu hình	`fusion_stage3`, fold 0, `predict_dataset='sarulab'` (mặc định), GPU Tesla T4 trên Colab
Dữ liệu train của model	BVCC, Sarulab data, Blizzard Challenges, SOMOS theo `docs/datasets.md`; không có tiếng Việt
Dữ liệu thử	30 câu song song Việt–Anh từ FLEURS (tập test), mỗi câu có bản đọc của người thật
Các điều kiện	Giọng người thật; 3 hệ TTS (Edge neural, MMS-TTS, gTTS) đọc cùng câu; giọng người thật thêm nhiễu trắng SNR 20, 10, 5, 0 dB

Hạng mục	Chi tiết
Khảo sát người nghe	20 clip tiếng Việt chọn sao cho điểm UTMOSv2 trải đều từ thấp đến cao; 4 thành viên nhóm chấm độc lập trên web, thang ACR 1–5 (ITU-T P.800), không biết clip thuộc hệ nào, không xem câu gốc, mỗi người nghe theo thứ tự ngẫu nhiên riêng

Trong 20 clip khảo sát có 4 clip người thật, 9 clip người thật có nhiễu và 7 clip TTS (4 MMS-TTS, 3 gTTS). Bộ 20 clip không có clip nào của Edge, nên phần khảo sát chỉ so được MMS-TTS và gTTS.

Kết quả khảo sát người nghe

Điểm UTMOSv2 không đi cùng chiều với điểm người nghe Việt. Sai lệch lớn nhất nằm ở TTS: người nghe chấm thấp nhất, model chấm cao nhất.



key.csv + ratings_detail.csv (utmosv2_vi_results.zip) · 20 clip, 4 người nghe, khảo sát ngày 7/11/2026

Người nghe tách rõ giọng người thật (3.63) với TTS (1.68), kiểm định Mann–Whitney p = 0.02. Với UTMOSv2, hai nhóm gần như bằng nhau (2.49 và 2.68, p = 0.79), và 6/7 clip TTS nằm trên trung vị điểm của model.

Chỉ số	Giá trị	Ý nghĩa
Tương quan Spearman (SRCC) theo clip	−0.01; khoảng tin cậy 95% từ −0.55 đến 0.51	Không có dấu hiệu model đi cùng chiều với người nghe
Tương quan Pearson (LCC) theo clip	0.03	Như trên
Sai số bình phương trung bình (MSE)	1.25	Lệch khoảng 1.1 điểm trên thang 5
SRCC trong nhóm người thật, có và không nhiễu (13 clip)	0.55 (p = 0.053)	Model theo kịp người nghe một phần
SRCC trong nhóm TTS (7 clip)	−0.19	Không theo kịp
Độ nhất quán giữa người nghe	SRCC từng cặp trung bình 0.37; độ tin cậy của điểm trung bình 4 người ≈ 0.71 (Spearman–Brown)	Đủ dùng cho chạy thử; từng người chấm khá khác nhau

Với 20 clip, khoảng tin cậy của SRCC còn rộng. Kết quả chưa chứng minh tương quan đúng bằng 0, nhưng loại trừ được mức tương quan từ khoảng 0.55 trở lên.

Ghi chú của người nghe cho thấy họ chấm khác model ở đâu:

- Clip gTTS được UTMOSv2 chấm 2.70 bị người nghe nhận xét “giọng đọc đều giống máy, không có nét tự nhiên” và “giọng của AI” (điểm trung bình 1.75).
- Clip người thật có nhiễu 5 dB được UTMOSv2 chấm 1.48 bị nhận xét “giọng tự nhiên nhưng âm thanh bị rè” (điểm trung bình 3.25). Người nghe tách độ tự nhiên của giọng khỏi chất lượng âm thanh, còn model trừ điểm cả hai.

Kết quả gián tiếp: so tiếng Việt với tiếng Anh

Trên 30 câu song song, UTMOSv2 chấm TTS tiếng Việt thấp hơn TTS tiếng Anh cùng hệ, nhưng chấm giọng người thật của hai thứ tiếng gần bằng nhau.

Điều kiện	Việt	Anh	Việt − Anh	p (Wilcoxon, theo cặp câu)
Người thật, sạch	2.66	2.85	−0.19	0.14
Edge neural	2.85	3.64	−0.79	< 0.001
gTTS	3.00	3.57	−0.56	< 0.001

Điều kiện	Việt	Anh	Việt − Anh	p (Wilcoxon, theo cặp câu)
MMS-TTS	2.57	2.96	−0.39	< 0.001
Nhiễu 20 dB	2.42	2.45	−0.03	0.81
Nhiễu 10 dB	2.14	1.86	+0.28	0.02
Nhiễu 5 dB	1.91	1.82	+0.09	0.30
Nhiễu 0 dB	1.80	1.80	+0.01	0.86

- **Chênh lệch chỉ xuất hiện ở TTS.** Chỉ riêng phần này thì chưa kết luận được là model thiên lệch: có thể TTS tiếng Việt thật sự kém hơn TTS tiếng Anh, và nhóm chưa có điểm người nghe tiếng Anh để so.
- **Model xếp giọng người thật dưới TTS ở cả hai thứ tiếng.** Tiếng Việt: gTTS > Edge > người thật > MMS-TTS. Tiếng Anh: Edge > gTTS > MMS-TTS > người thật. Bản ghi FLEURS do tình nguyện viên thu bằng micro khác nhau, nên có thể model đang trừ điểm chất lượng thu âm. Một phần sai lệch ở phần khảo sát có thể đến từ điều này, không chỉ từ ngôn ngữ.
- **Phản ứng với nhiễu như nhau.** Tương quan Spearman giữa mức SNR và điểm là 0.60 ở tiếng Việt và 0.61 ở tiếng Anh. Từ sạch xuống 0 dB, điểm giảm 0.86 ở tiếng Việt và 1.05 ở tiếng Anh. Model vẫn nhận ra suy giảm âm học trên tiếng Việt.

Nhận xét và kết luận

Kết quả chạy thử ủng hộ nhận định của thầy: với tiếng Việt, UTMOSv2 chưa thay được người nghe trong việc đánh giá độ tự nhiên, nhất là với giọng tổng hợp.

1. **Model hỏng đúng ở việc cần làm nhất.** Một bộ dự đoán MOS dùng để chấm TTS, nhưng UTMOSv2 không phân biệt được TTS tiếng Việt mà người nghe chê là “giọng máy” với giọng người thật.
2. **Phần âm học vẫn chuyển sang được.** Model nhận ra nhiễu trên tiếng Việt gần như trên tiếng Anh. Phần còn thiếu nhiều khả năng là cảm nhận độ tự nhiên riêng của tiếng Việt như thanh điệu và nhịp điệu. Đây mới là giả thuyết, lần chạy thử này chưa kiểm chứng.
3. **Hàm ý cho đề tài.** Muốn có bộ dự đoán MOS dùng được cho tiếng Việt thì cần dữ liệu MOS tiếng Việt do người nghe chấm, rồi fine-tune model có sẵn như UTMOSv2 trên dữ liệu đó. Quy trình ở đây (chọn mẫu theo điểm, web khảo sát, notebook tổng hợp) dùng lại được để thu dữ liệu lớn hơn.

Hạn chế và hướng tiếp theo

Đây là lần chạy thử trên mẫu nhỏ. Kết luận đủ để xác nhận vấn đề là có thật, chưa đủ để đo mức độ chính xác.

- **Mẫu nhỏ.** Có 20 clip, mỗi điều kiện chỉ 2–4 clip, nên điểm theo điều kiện trong biểu đồ chỉ để tham khảo. Ví dụ, người nghe chấm nhiễu 0 dB cao hơn nhiễu 10 dB, nhiều khả năng do khác nội dung câu chứ không phải do nhiễu.
- **Người nghe là 4 thành viên nhóm.** Họ không phải người nghe ngẫu nhiên, và mức đồng thuận giữa từng cặp chỉ ở mức vừa (SRCC 0.37).
- **Chưa có đối chứng tiếng Anh.** Chưa tách được phần sai do ngôn ngữ với phần sai do miền dữ liệu, ví dụ chất lượng thu âm của FLEURS hay các giọng TTS cụ thể.
- **Cách hiểu "tự nhiên" với clip có nhiễu.** Người nghe chấm giọng, bỏ qua tạp âm; model trừ điểm cả tạp âm. Lần sau cần hướng dẫn rõ có tính chất lượng âm thanh vào điểm hay không.
- **Phạm vi.** Chỉ dùng một cấu hình model, và bộ khảo sát không có Edge.

Bước tiếp theo hợp lý: mở rộng lên vài trăm clip, thêm người nghe ngoài nhóm và các hệ TTS tiếng Việt phổ biến, kèm một bài nghe tiếng Anh nhỏ để đối chứng.

Phụ lục: demo và cách tái lập

Toàn bộ kết quả trên tái lập được bằng notebook Colab đính kèm: chọn GPU T4 rồi Run all, kết quả được lưu vào Google Drive.

Tệp	Nội dung
`UTMOSv2_TiengViet_Demo.ipynb`	Cài UTMOSv2, tải FLEURS, sinh TTS và nhiễu, chấm điểm, phân tích, sinh báo cáo; cell 6 cho nghe và xem điểm từng mẫu
Web khảo sát (GitHub Pages): https://thachhaoo.github.io/voice-survey/	20 clip, thang ACR 1–5, xuất file điểm của từng người
`utmosv2_vi_results.zip`	`scores.csv` (điểm UTMOSv2 của 480 file), `key.csv` (clip → hệ, câu, điểm), `ratings_detail.csv` (80 lượt chấm), biểu đồ